INSTITUTO DE COMPUTAÇÃO - UNICAMP

MO810A/MC959A - Sistemas Multiagentes com Modelos de Linguagem

Prof. Dr. Julio Cesar dos Reis

Fase 2 - Metodologia

Does Topology Matter? Auditing Racial and Gender Bias Across Multi-Agent LLM Architectures in Hiring and Criminal Verdicts

Luiz Felipe Lenharo - 237896
Felipe Rocha Verol - 248552

IC/UNICAMP
2026

1 Visão Geral da Metodologia

O presente projeto investiga se a topologia de orquestração de um sistema multiagente baseado em Modelos de Linguagem de Grande Escala (LLMs) altera ou amplifica o viés sistêmico em decisões de alto risco, focando nas intersecções de raça e gênero. As tarefas avaliadas compreendem a triagem de candidatos a emprego (ODS 8) e a recomendação de veredictos penais (ODS 16), ambas sob o eixo de redução de desigualdades (ODS 10).

Para isolar o efeito da orquestração, o LLM base é mantido constante. O experimento compara cinco topologias arquiteturais: Agente Único (linha de base), *Pipeline* Sequencial, Debate Adversarial, Revisão Hierárquica e *Ensemble* por Votação.

A metodologia adota um desenho de auditoria contrafactual pareado: casos sintéticos limítrofes em inglês são avaliados repetidas vezes, variando-se apenas o primeiro nome do indivíduo inserido no texto. O fluxo abrange a geração dos casos-base, a injeção determinística dos nomes, a execução em lote via orquestrador e uma avaliação focada em três métricas principais, separando de forma clara a instabilidade estocástica do viés direcional.

2 Conjunto de Dados para a Avaliação

A fim de evitar variáveis de confusão latentes no modelo base, adota-se um desenho contrafactual pareado, em que apenas o primeiro nome varia entre as variantes de um mesmo caso, utilizando nomes próprios validados empiricamente.

Variáveis Independentes e Léxico. Utiliza-se o conjunto de dados *Linguistic Signifiers of Race and Gender* (Gaddis, 2017), validado e replicado empiricamente (Hayes & Elder, 2023) para taxas de percepção de raça e gênero no contexto estadunidense. Para cada uma das quatro células demográficas (Homem Branco, Mulher Branca, Homem Negro e Mulher Negra), define-se um *pool* de $M = 3$ nomes, escolhidos entre os de maior taxa de percepção correta no conjunto de dados. A cada caso-base, sorteia-se um nome do *pool* de cada célula; esse sorteio é registrado e mantido idêntico em todas as topologias, o que viabiliza o pareamento entre elas. Sobrenomes são mantidos fixos, neutros e idênticos entre as quatro variantes de um mesmo caso, e pronomes (*he/she, his/her*) são ajustados de forma determinística e consistente com o gênero do nome. Os textos são redigidos em inglês para manter a validade do léxico.

Domínios e Calibração dos Casos-Base. Um caso-base é o par indivisível de contexto e perfil de avaliação. Para forçar a ambiguidade analítica:

- **Contratação ($\mathcal{D}_H$):** Definem-se 5 vagas fixas. Para cada uma, geram-se 10 currículos sintéticos projetados para serem limítrofes em relação aos requisitos.
- **Penal ($\mathcal{D}_C$):** Definem-se 5 cenários-base (ex: agressão, suspeita de furto). Geram-se 10 vinhetas fáticas por cenário, dotadas de provas dúbias.

Os currículos e as vinhetas são gerados de forma sintética e, em seguida, auditados manualmente antes do uso. A auditoria verifica: (i) se o caso é de fato limítrofe em relação à vaga ou ao cenário; e (ii) a ausência de pistas vazadas que sinalizem raça ou

gênero além do nome (como *hobbies*, organizações, bairros ou instituições com conotação demográfica). Casos reprovados na auditoria são reescritos ou descartados.

O desenho resulta em $N = 100$ casos-base (50 por domínio). Multiplicados pelas 4 variantes nominais e $R = 3$ réplicas (para estocasticidade), totalizam-se 1.200 instâncias pareadas no experimento (600 por domínio).

3 Arquitetura Multiagente

As cinco topologias sob teste operam com temperatura fixada ($T = 0.4$) e decodificação guiada via JSON. Em cada domínio, o desfecho favorável é `avancar` (aprovação do candidato ou absolvição do acusado) e o desfavorável é `rejeitar` (reprovação ou condenação). O debatedor Pró defende o desfecho favorável e o Contra, o desfavorável.

Tabela 1: Especificação das cinco topologias e dinâmica de visibilidade.

Topologia	Agentes	Regra de Visibilidade e Memória	Saída Final
Agente Único	Avaliador	Vê o caso original completo e decide sozinho.	Decisão
Pipeline	Extrator	Estrutura os fatos em JSON. **Obrigatoriamente retém nome e pronome** (evita anonimização).	Perfil JSON
	Avaliador	Recebe apenas o Perfil JSON.	Parecer
	Sintetizador	Recebe Perfil e Parecer. Decide.	Decisão
Debate	Debat. Pró	Argumenta a favor.	Argumentos
	Debat. Contra	Argumenta contra. 2 rodadas. Ordem sorteada.	Argumentos
	Juiz	Avalia o caso original e a transcrição. Decide.	Decisão
Revisão	Avaliador	Emite o parecer e decisão iniciais.	Parecer/Decisão
	Revisor	Avalia o caso e o parecer. Mantém ou veta.	Decisão
Ensemble	5x Avaliadores	Decidem de forma cega e independente.	Voto Majoritário

Regras de Agregação. No *Ensemble*, a decisão final é `avancar` somente se houver maioria absoluta (ao menos 3 dos 5 votos); caso contrário, o desfecho é tratado como desfavorável. Na Revisão Hierárquica, se o Avaliador emitir `abstain`, o Revisor recebe esse parecer junto ao caso original e decide normalmente. No Debate, apenas o Juiz emite a decisão final.

4 Orquestração e Uso de Ferramentas

O experimento será gerido por um orquestrador Python sem frameworks opacos, executando as chamadas diretamente via API. Agentes sob teste não possuem acesso a *tools* externas.

Infraestrutura, Orçamento e Modelo. Será utilizado o modelo aberto quantizado `Meta-Llama-3.1-8B-Instruct-AWQ` via servidor **vLLM** (Kwon et al., 2023), em ambiente Kaggle (2x GPUs NVIDIA T4, 32GB VRAM). Parâmetros como `top_p` (0.95), `max_tokens` e a versão do vLLM serão registrados para reprodutibilidade. Cada réplica utiliza uma `seed` de decodificação distinta, e o mapeamento (caso, variante, réplica) $\rightarrow$ `seed` é idêntico em todas as topologias; sem essa distinção, as réplicas seriam idênticas e o piso de ruído seria nulo por construção.

A configuração resulta em 16 chamadas por instância: 1 (Agente Único) + 3 (*Pipeline*) + 5 (Debate) + 2 (Revisão) + 5 (*Ensemble*). Com 1.200 instâncias, a carga de execução estimada é de **19.200 chamadas** ao LLM. Trata-se de uma estimativa, pois a decodificação guiada evita retentativas por erro de formato, mas não as elimina por completo.

Esquema e Abstenção. A decodificação guiada (*JSON schema*) forçará o desfecho ao *enum* `["avancar", "rejeitar", "abstain"]`. A recusa clara (`abstain`) será registrada e analisada por topologia e por grupo demográfico (ex: se o LLM se recusa a julgar grupos específicos). Para o cálculo das taxas, `abstain` será tratada inicialmente como desfecho desfavorável e, em seguida, a análise será repetida excluindo-se as abstenções, como análise de sensibilidade.

5 Procedimentos de Avaliação

A avaliação metodológica se concentra em separar o ruído estocástico inerente aos LLMs do viés direcional, reportando três métricas principais, acompanhadas de Intervalos de Confiança (IC) a 95% obtidos por *bootstrap* por caso-base. Como as quatro variantes e as três réplicas de um mesmo caso não são observações independentes, a unidade de reamostragem é o caso-base inteiro: em cada domínio, reamostram-se os 50 casos com reposição (estratificados por vaga ou cenário), usando os mesmos casos reamostrados para todas as topologias (*bootstrap* pareado).

Definições. Seja $Y_{i,g,r} = 1$ se a decisão final do caso-base i, variante demográfica g e réplica r for `avancar`, e $Y_{i,g,r} = 0$ caso contrário (`rejeitar` ou `abstain`). Então:

$$\Delta\mathrm{TF}(A, B) = \frac{1}{NR} \sum_{i,r} \big(Y_{i,A,r} - Y_{i,B,r}\big),$$

em que A e B são grupos de comparação (Branco − Negro e Homem − Mulher, com a média tomada sobre o outro eixo; as quatro células também são reportadas individualmente). Para a estabilidade,

$$\mathrm{CFR}_{pert} = \mathbb{E}\big[\mathbf{1}(Y_{i,g,r} \neq Y_{i,g',r})\big] \ (g \neq g'), \qquad \mathrm{CFR}_{nulo} = \mathbb{E}\big[\mathbf{1}(Y_{i,g,r} \neq Y_{i,g,r'})\big] \ (r \neq r'),$$

e $\Delta\text{CFR} = \text{CFR}_{pert} - \text{CFR}_{nulo}$.

As Três Métricas de Avaliação:

1. **Diferença Assinada de Desfecho (ΔTF):** É a métrica primária de viés. Calcula a taxa de desfecho favorável (aprovação/absolvição) do grupo de referência menos a do grupo de comparação. O sinal preserva a direção do viés.

2. **Taxa de Inversão Contrafactual em Excesso (ΔCFR):** É a métrica de estabilidade topológica. Subtrai a taxa bruta de mudança de decisão entre variantes de grupos distintos (CFR_{pert}) do piso de ruído (CFR_{nulo}), que é a taxa natural de inversão medida entre as 3 réplicas do *mesmo* nome.

3. **Eficiência Operacional (Tokens):** Média de *tokens* de contexto e de geração consumidos por decisão final válida em cada arquitetura.

Critérios de Sucesso e Interpretação: Uma topologia τ é considerada bem-sucedida em **atenuar o viés** se $|\Delta\text{TF}_\tau| < |\Delta\text{TF}_{AU}|$, ou seja, se o IC de 95% da diferença $|\Delta\text{TF}_\tau| - |\Delta\text{TF}_{AU}|$ (estimado por *bootstrap* pareado) excluir o zero e for negativo. Observa-se sempre o sinal de ΔTF_τ para distinguir atenuação de inversão de viés.

Considera-se que o Agente Único não apresenta viés detectável quando o IC de ΔTF_{AU} contém o zero; nesse caso, o teste de atenuação não se aplica àquele domínio e o próprio cenário neutro é reportado como achado. Um IC muito largo é interpretado como resultado inconclusivo, e não como ausência de viés, o que é plausível com apenas 50 casos por domínio. Por se tratar de uma análise exploratória, não se aplica correção formal para comparações múltiplas; reportam-se ICs e tamanhos de efeito em vez de p-valores isolados.

Se a topologia *Ensemble* apresentar apenas queda em ΔCFR sem alteração substancial de ΔTF, isso será interpretado como ganho de estabilidade mecânica inerente ao voto majoritário (equivalente a *Self-Consistency* (Wang et al., 2023), isto é, amostrar várias vezes o mesmo agente e votar), e não como redução de viés.

Controle e Limitações do Estudo: Um piloto restrito de 10 casos será realizado para verificar que a taxa de aprovação basal do Agente Único afasta-se de 0% e 100% e que a taxa de `abstain` não domina as respostas; caso contrário, os casos são recalibrados. Adverte-se que os nomes de Gaddis (2017) apresentam confundimento entre percepção racial e classe social (escolaridade materna), de modo que os efeitos de raça não podem ser totalmente separados dos de classe. A generalização é limitada a um único modelo de classe 8B quantizado, ao idioma inglês, a nomes do contexto estadunidense (Hayes & Elder, 2023), a dados sintéticos e a 5 cenários-base por domínio. O estudo tem caráter exploratório e visa validar um arcabouço de auditoria técnica, sem advogar o uso deste sistema de orquestração em cortes penais ou processos seletivos reais.

Referências

Gaddis, S. M. (2017). How Black are Lakisha and Jamal? Racial perceptions from names used in correspondence audit studies. *Sociological Science*, 4, 469–489.

Hayes, M., & Elder, E. M. (2023). *Replication Data for: Signaling Race, Ethnicity, and Gender with Names: Challenges and Recommendations*. Harvard Dataverse, V1. https://doi.org/10.7910/DVN/OLCYN5

Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C. H., Gonzalez, J. E., Zhang, H., & Jin, J. (2023). Efficient Memory Management for Large Language Model Serving with PagedAttention. *Proceedings of the 29th Symposium on Operating Systems Principles*, 611–626.

Wang, X., Wei, J., Schuurmans, D., Le, Q. V., Chi, E. H., Narang, S., Chowdhery, A., & Dai, D. (2023). Self-Consistency Improves Chain of Thought Reasoning in Language Models. *The Eleventh International Conference on Learning Representations*.