

MO810A/MC959A · SISTEMAS MULTIAGENTES COM MODELOS DE LINGUAGEM · FASE 1 — PROPOSTA

Does Topology Matter?

Auditing Socioeconomic Bias Across Multi-Agent LLM Architectures in Hiring and Criminal Verdicts

Luiz Felipe Lenharo — 237896 · **Felipe Rocha Verol** — 248552
Instituto de Computação · UNICAMP · Prof. Dr. Julio Cesar dos Reis · 2026

De uma chamada única à arquiteturas multiagentes

Empresas de recrutamento e ferramentas jurídicas delegam pré-análise de casos sensíveis, cada vez mais, à **Sistemas Multi Agente (MAS)** — via AutoGen, MetaGPT, CrewAI.

Topologia importa (desempenho)

Trocar só a orquestração, modelo fixo: −41% custo, −44% tempo, −38% tokens, qualidade quase constante.

Sayed Ali et al., 2026

Viés existe (agente único)

Embeddings favorecem nomes de candidatos brancos em 85,1% dos casos; juízes-LLM mostram viés socioeconômico em até 10/13 modelos.

Wilson & Caliskan 2024 · Hu et al. 2025

ODS 10 (Desigualdades) · ODS 8 (emprego) · ODS 16 (justiça).

MOTIVAÇÃO

Três fatores para o tema

- **Social** — decisões automatizadas em contratação e justiça penal afetam diretamente o acesso de grupos vulneráveis a oportunidades e a tratamento justo.
- **Científico** — a auditoria de viés existente foca no agente único; falta entender como a *topologia* multiagente atenua, amplifica ou preserva esse viés.
- **Tecnológico/prático** — pipeline, debate e ensemble já rodam em produtos reais de HR-tech e legal-tech sem metodologia de auditoria replicável para comparar topologias antes da adoção.

Beneficiários: candidatos/réus (indiretamente) e equipes de engenharia/reguladores que precisam auditar uma topologia antes de produção.

A lacuna: o que a literatura ainda não sabe

O problema é a **falta de explicação da variância** do viés socioeconômico observado em avaliações de agente único quando o mesmo modelo-base é organizado em diferentes topologias multiagente.

Linha 1 — viés

Documentado em triagem de currículo e decisão penal, sempre com agente único.

Linha 2 — topologia

Documentado que muda custo/robustez/desempenho, mas nenhum trabalho mede viés socioeconômico.

MAIS PERTO Li et al. [2026] mostram amplificação de viés demográfico por topologia — mas em domínios sintéticos, com rótulos categóricos explícitos, sem eixo socioeconômico e sem emprego+penal juntos.

Este projeto: comparação pareada contrafactual sobre um único candidato, sem categorização demográfica explícita — mede *deslocamento de pontuação*, não preferência entre grupos rotulados.

ESCOPO

Dentro e fora do projeto

✓ DENTRO DO ESCOPO

- Uma característica socioeconômica por vez (bairro/CEP, nome, instituição de ensino, histórico penal)
- Duas tarefas: triagem de emprego & veredicto penal
- Conjunto definido de arquiteturas + linha de base de agente único

× FORA DO ESCOPO

- Implantação ou teste com usuários reais
- Fine-tuning ou alteração dos LLMs
- Explicação causal do mecanismo interno (mede *se* e *quanto*, não *por quê*)
- Eixos de viés fora de status socioeconômico (exceto interseccionalidade)

Benchmark de auditoria por comparação pareada contrafactual

Para cada tarefa, o benchmark gera **pares de casos idênticos** exceto por uma característica correlacionada a status socioeconômico. Cada arquitetura avalia todos os casos; compara-se a diferença de pontuação par a par.

01

Agente único

Linha de base — referência para o efeito líquido de multiagentes.

02

Pipeline sequencial

Extração → avaliação → síntese, em série.

03

Debate/adversarial

Dois agentes argumentam, um terceiro julga.

04

Revisão hierárquica

Avaliador supervisionado por revisor com veto.

05

Ensemble/votação

Agentes independentes, resultado agregado.

MÉTRICAS

CFR e MASD — complementares, não redundantes

MÉTRICA PRINCIPAL

Counterfactual Flip Rate (CFR)

Frequência de reversão da decisão binária entre um par contrafactual. Reflete o desfecho de interesse — a decisão — mas satura quando a maioria dos pares não inverte.

MÉTRICA SECUNDÁRIA

Mean Absolute Score Difference (MASD)

Deslocamento médio da pontuação entre pares. Diagnostica viés mesmo sem reversão — mais sensível a efeitos pequenos e consistentes.

Definições operacionais de [Mayilvaghanan et al. 2026](#) e [Morla et al. 2026](#), aplicadas de forma idêntica a todas as arquiteturas.

Trabalhos mais próximos e a adaptação exigida

REFERÊNCIA	CONTRIBUIÇÃO	LACUNA PI/ ESTE PROJETO
Wilson & Caliskan 2024	85,1% viés pró-branco em retrieval de currículo	Modelo único de retrieval, não decisão multiagente
Gallegos et al. 2024	Survey — taxonomia de métricas e mitigação	Métricas nativas a LLM único, não a ações multiagente
Morla et al. 2026	CFR/MASD, agência crescente incl. multiagente	Contratação/crédito/saúde — sem domínio penal
Okawa 2026	Transição de fase → consenso enviesado em debate	Validado em investimento/LLM-judge, não emprego/penal
Madigan et al. 2025	Viés multiagente não é redutível ao individual	Domínio financeiro, não emprego/penal
Bonil et al. 2025	Viés racial/gênero em LLM generativo (PT-BR)	Análise discursiva/qualitativa, não decisão quantitativa

SÍNTESE

**A topologia de orquestração
atenua, amplifica ou preserva
o viés socioeconômico observado
em agente único?**

Comparação pareada contrafactual · 2 tarefas · 5 arquiteturas · CFR + MASD

Obrigado.

Perguntas e discussão.

Luiz Felipe Lenharo · Felipe Rocha Verol — IC/UNICAMP, 2026