
INSTITUTO DE COMPUTAÇÃO - UNICAMP
MO810A/MC959A - Sistemas Multiagentes com Modelos de
Linguagem
Prof. Dr. Julio Cesar dos Reis

Fase 1 - Proposta

*Does Topology Matter? Auditing Socioeconomic Bias Across
Multi-Agent LLM Architectures in Hiring and Criminal Verdicts*

Luiz Felipe Lenharo - 237896
Felipe Rocha Verol - 248552

1 Cenário e Contexto

Este trabalho se insere na área de IA aplicada à justiça social e equidade algorítmica, especificamente na auditoria de viés em sistemas multiagentes baseados em Modelos de Linguagem (LLMs). O tema se conecta diretamente ao ODS 10 (Redução das Desigualdades), com aplicação em dois domínios que instanciam outros dois ODS: avaliação de candidatos a vagas de emprego (ODS 8 – Trabalho Decente e Crescimento Econômico) e apoio à decisão em veredictos de júri penal (ODS 16 – Paz, Justiça e Instituições Eficazes).

O problema ocorre em organizações como empresas de recrutamento, plataformas de triagem de currículos, ferramentas de apoio a decisões jurídicas e outras, que vêm delegando etapas de pré-análise de casos sensíveis a sistemas baseados em LLM. Diferente de uma única chamada a um modelo, esses sistemas são cada vez mais construídos como arquiteturas multiagentes, em que múltiplos agentes (por exemplo, extrator de perfil, avaliador, crítico/revisor, agregador de opiniões) cooperam ou competem para produzir uma decisão final. Frameworks como AutoGen, MetaGPT e CrewAI popularizaram esse tipo de orquestração, e há evidências de que a topologia de orquestração (pipeline, hierárquica, debate, ensemble, etc.) afeta métricas como custo, robustez e desempenho da tarefa: trocar apenas a camada de orquestração, mantendo o modelo fixo, já foi mostrado reduzir custo por tarefa em 41%, tempo em 44% e tokens em 38%, com qualidade de tarefa praticamente constante [Sayed Ali et al., 2026].

Paralelamente, existe uma linha de pesquisa que demonstra que LLMs isolados replicam vieses raciais e de gênero quando avaliam currículos: modelos de embedding favorecem nomes associados a candidatos brancos em 85,1% dos casos testados [Wilson and Caliskan, 2024]. Esse achado, no entanto, não é estático entre gerações de modelo – um levantamento com 14 LLMs (Gao, Jiang & Yan, arXiv:2606.28978) mostrou que o modelo de 2023 reproduz o viés pró-branco documentado na literatura de discriminação no mercado de trabalho, mas todo modelo de 2024 em diante mostra reversão (viés pró-preto) ou gap não significativo. **[FALTA: essa citação ainda não está formatada no referenc.bib porque o achado é uma reversão, não um viés simples – decidir junto com o grupo como enquadrar esse resultado antes de formalizar a entrada bib]** Um survey consolidado documenta como LLMs de forma geral aprendem, perpetuam e amplificam vieses sociais [Gallegos et al., 2024]. Em português, há evidência local de que LLMs generativos reforçam discursos dominantes de raça e gênero em narrativas geradas [Bonil et al., 2025]. Para o eixo de justiça penal, **[FALTA: referência de viés racial/socioeconômico em decisão penal por LLM ainda não confirmada – ver ressalvas sobre Ganguli et al. (2022) e ICE-Guard na revisão de referências, nenhuma das duas está pronta pra citar aqui sem verificar o corpo do texto]**.

O que ainda não está bem estabelecido na literatura é como esse viés se comporta quando o mesmo modelo-base é inserido em diferentes arquiteturas multiagentes: se a orquestração atenua, amplifica ou não altera o viés observado em avaliações de agente único. Há indícios de que a interação entre agentes pode amplificar vieses individuais e produzir normas coletivas enviesadas em debates multiagentes [Okawa, 2026], e evidência (em domínio financeiro, não em emprego/penal) de que o viés de um sistema multiagente não é redutível ao viés dos componentes individuais, o que sustenta a necessidade de avaliação holística do sistema [Madigan et al., 2025].

2 Motivação para o Tema

A escolha do tema é motivada por três fatores. Primeiro, um fator social: a desigualdade socioeconômica é um problema crescente e mensurável, e decisões automatizadas em contratação e justiça penal afetam diretamente o acesso de grupos vulneráveis a oportunidades econômicas e a tratamento justo perante a lei. Segundo, um fator científico/tecnológico: há preocupação documentada de que LLMs aprendam, perpetuem e amplifiquem vieses sociais presentes nos dados de treinamento [Gallegos et al., 2024], mas a maior parte da auditoria de viés em LLM foca em modelo único; falta entender se arquiteturas multiagentes (cada vez mais adotadas em produtos reais de HR-tech e legal-tech) mudam esse comportamento. Terceiro, um fator prático: entender esse comportamento é pré-requisito para responder, com rigor, se sistemas multiagentes são de fato adequados para pré-análise de casos sensíveis – hoje isso é uma pergunta em aberto, não um pressuposto do projeto.

O impacto esperado tem dois grupos de beneficiários e mecanismos distintos: (i) candidatos a emprego e réus/acusados, que seriam protegidos indiretamente caso o benchmark leve à identificação e ao desencorajamento de arquiteturas que amplificam viés discriminatório; e (ii) equipes de engenharia e reguladores que precisam escolher ou auditar uma topologia de orquestração antes de colocá-la em produção, para os quais o benchmark funcionaria como uma metodologia de comparação replicável entre arquiteturas.

3 Caracterização do Problema

O problema é a falta de explicação da variância, do viés socioeconômico observado em avaliações feitas por um único agente LLM quando o mesmo modelo-base é organizado em diferentes topologias de sistemas multiagentes, nas tarefas de triagem de candidatos a emprego e de recomendação em veredictos de júri penal.

A lacuna se sustenta em duas frentes de evidência que, isoladamente, não respondem à pergunta: de um lado, há estudos que documentam viés em avaliações de agente único por LLM [**FALTA: referências específicas de viés em triagem de currículo e/ou decisão penal por LLM**]; de outro, há estudos que mostram que a topologia de orquestração multiagente altera métricas de desempenho, custo e robustez da tarefa (ex.: AutoGen, MetaGPT, e trabalhos sobre economia de tokens em diferentes arquiteturas de orquestração), mas nenhum desses trabalhos mede viés socioeconômico como variável de interesse. A interseção entre as duas linhas – efeito da topologia sobre o viés, especificamente – [**FALTA: confirmar se essa lacuna é explicitamente apontada em algum survey/related work, ou se a alegação de ineditismo se sustenta apenas por ausência de resultado nas buscas realizadas**].

As consequências de não resolver essa lacuna são práticas e científicas: praticamente, produtos de HR-tech e legal-tech que adotam múltiplos agentes podem estar transmitindo uma falsa sensação de segurança (“mais agentes deliberando = decisão mais justa”) sem evidência que sustente essa suposição; cientificamente, falta uma metodologia comparável para avaliar como escolhas de design de orquestração interagem com equidade algorítmica.

O projeto aborda: (i) analise controlada via comparação pareada contrafactual, variando uma única característica correlacionada a status socioeconômico por vez e mantendo as demais constantes; (ii) duas tarefas de decisão (triagem de candidatos, recomendação

de veredicto penal); (iii) um conjunto definido de arquiteturas multiagentes, incluindo uma linha de base de agente único como referência de comparação. Fora do escopo do estudo: (i) implantação ou teste com usuários reais; (ii) fine-tuning ou alteração dos modelos de linguagem subjacentes; (iii) explicação causal do mecanismo interno pelo qual a topologia influencia o viés (o projeto mede *se e quanto*, não necessariamente *por quê*); (iv) eixos de viés não relacionados a status socioeconômico, exceto quando necessários para caracterizar interseccionalidade.

4 Proposta de Solução Conceitual

A proposta é um benchmark de auditoria de viés por comparação pareada contrafactual, aplicado a um conjunto de arquiteturas multiagentes candidatas. Para cada tarefa (triagem de emprego e veredicto penal), o benchmark gera pares de casos idênticos exceto por uma única característica correlacionada a status socioeconômico (ex.: bairro/CEP como proxy de renda, nome do candidato, prestígio da instituição de ensino, histórico penal contextualizado). Cada arquitetura avalia todos os casos e atribui uma pontuação atrelada à decisão tomada; o benchmark compara, par a par, a diferença de pontuação atribuída a casos que só diferem em uma característica.

As arquiteturas candidatas, cada uma contribuindo para isolar um mecanismo diferente pelo qual o viés poderia se propagar, são:

- **Agente único** (linha de base): um único agente LLM realiza a avaliação completa, servindo como referência para medir o efeito líquido de introduzir múltiplos agentes.
- **Pipeline sequencial**: agentes especializados (ex.: extração de perfil, avaliação, síntese) atuam em série, testando se a decomposição em etapas concentra ou dilui viés presente em uma etapa específica.
- **Debate/adversarial**: dois agentes argumentam posições opostas e um terceiro agente julga, testando se o confronto de perspectivas expõe ou neutraliza um viés individual.
- **Revisão hierárquica**: um agente avaliador é supervisionado por um agente revisor com poder de veto/ajuste, testando se a supervisão corrige ou herda o viés do avaliador.
- **Ensemble/votação**: múltiplos agentes avaliam independentemente e o resultado é agregado (média ou voto), testando se a agregação estatística atenua vieses individuais.

A contribuição de cada arquitetura para a solução é, portanto, permitir isolar um mecanismo estrutural específico (especialização em série, confronto adversarial, supervisão hierárquica, agregação estatística) e compará-lo contra a linha de base de agente único, sem a qual não é possível atribuir uma diferença observada à topologia em si. A métrica de viés usada para comparar os pares tem candidatas já formalizadas na literatura: a *Counterfactual Flip Rate* (CFR), frequência de reversão da decisão binária entre um par contrafactual, e a *Mean Absolute Score Difference* (MASD), deslocamento médio da pontuação entre os pares [Mayilvaghanan et al., 2026, Morla et al., 2026]. O desenho

experimental mais próximo do proposto neste projeto é o de Morla et al. [2026], que avalia perfis sintéticos pareados variando apenas um sinal nome-codificado de raça/gênero sob scaffolds de agência crescente (direto, cadeia de pensamento, deliberação multiagente, uso de ferramentas) – porém cobrindo contratação, crédito e triagem médica, sem o domínio penal. A métrica escolhida é aplicada de forma idêntica a todas as arquiteturas, permitindo comparação direta entre elas.

5 Posicionamento em Relação ao Estado da Arte

Da lista [Awesome Agentic Systems](#), nenhum artigo trata de viés/equidade – a lista é focada em arquitetura, memória, ferramentas e avaliação de agentes. Os candidatos mais próximos do projeto, por tratarem de topologia de orquestração multiagente, são AutoGen e MetaGPT (arquiteturas de referência para as topologias de debate/pipeline propostas na Seção 4) e Sayed Ali et al. [2026] (evidência de que a topologia de orquestração muda custo e desempenho, mas não trata de viés).

Como a lista-base não cobre viés/equidade, as referências abaixo vêm de fora dela, conforme permitido pelo enunciado. Cada uma é apresentada com critério de seleção, o que foi extraído, e a adaptação exigida para o problema da Seção 3:

- **Wilson and Caliskan [2024]** – *Critério*: mede viés racial/de gênero em triagem de currículo por modelos de linguagem, um dos dois domínios do projeto. *Extraído*: modelos de embedding favorecem nomes associados a candidatos brancos em 85,1% dos casos, com efeito interseccional mais forte contra homens negros. *Adaptação*: o método audita um modelo de retrieval único, não uma arquitetura multiagente de decisão; é preciso adaptar o desenho pareado contrafactual para pontuação/decisão de agentes orquestrados, não apenas ranqueamento de documentos.
- **Gallegos et al. [2024]** – *Critério*: survey de referência para fundamentar a definição de viés e as métricas de avaliação usadas no projeto. *Extraído*: taxonomia de métricas de viés (embeddings, probabilidades, texto gerado) e de técnicas de mitigação por estágio de intervenção. *Adaptação*: o survey trata de LLM único; nenhuma das métricas listadas é nativa para decisão multiagente, exigindo adoção de métricas específicas para sistemas de ação (ver Morla et al. [2026] abaixo).
- **Morla et al. [2026]** – *Critério*: benchmark de viés para *ações* de agentes LLM (não apenas texto gerado), com desenho pareado contrafactual e arquiteturas de agência crescente incluindo multiagente – o desenho mais próximo do projeto. *Extraído*: definição operacional de CFR e MASD, e o "arity matched null methodology" para evitar inflar disparidade aparente por artefato estatístico (2,4x). *Adaptação*: cobre contratação, crédito e triagem médica, não justiça penal; é preciso estender o desenho pareado para o domínio de veredicto penal e para as topologias específicas do projeto (debate, revisão hierárquica).
- **Okawa [2026]** – *Critério*: trata diretamente de viés emergente em *debates* multiagentes, uma das topologias candidatas do projeto. *Extraído*: previsão teórica (baseada em dinâmica social) de uma transição de fase para consenso enviesado

quando conformidade entre agentes ultrapassa um limiar, e evidência de que heterogeneidade dos agentes suprime esse efeito. *Adaptação*: o modelo teórico é validado em tarefas de decisão de investimento e LLM-as-a-judge, não em contratação/penal; a hipótese de transição de fase precisaria ser testada especificamente nos domínios do projeto.

- **Madigan et al. [2025]** – *Critério*: mostra que viés em sistema multiagente não é redutível ao viés dos agentes individuais, sustentando a necessidade de avaliação holística – argumento central da Seção 3. *Extraído*: em simulações financeiras, viés emerge de mecanismos de comunicação/colaboração entre agentes, não apenas dos componentes. *Adaptação*: domínio é finanças (credit scoring, income estimation); o mecanismo (viés emergente de interação) precisa ser testado nos domínios de emprego e penal, que têm dinâmicas de decisão distintas do financeiro.
- **Bonil et al. [2025]** – *Critério*: evidência local (PT-BR, IC/UNICAMP) de viés racial/de gênero em LLM generativo, complementando a literatura predominantemente em inglês/contexto americano. *Extraído*: análise discursiva mostrando que LLMs retratam mulheres negras via ancestralidade/resistência e mulheres brancas via autodescoberta, com correções superficiais de viés. *Adaptação*: método é qualitativo/discursivo sobre narrativas geradas, não quantitativo sobre decisões de triagem/veredicto; o projeto precisaria traduzir a categoria de análise (discurso) para uma métrica quantitativa comparável entre arquiteturas.

Ainda em aberto: uma referência específica de viés racial/socioeconômico em *decisão penal* por LLM. Dois candidatos foram levantados (Ganguli et al. 2022, arXiv:2202.07785; ICE-Guard, arXiv:2603.18530) mas nenhum está pronto para citar aqui – o primeiro não menciona COMPAS/reincidência em seu abstract (precisa verificar o corpo do texto antes de usar essa alegação) e o segundo confirma validação contra dados COMPAS reais mas não confirma, no abstract, que contratação é um dos 10 domínios testados. **[FALTA: ler os dois papers na íntegra antes de decidir se entram nesta seção]**.

Apêndice

<Use se necessário. >

Referências

- Gustavo Bonil, Simone Hashiguti, Jhessica Silva, João Gondim, Helena Maia, Nádia Silva, Helio Pedrini, and Sandra Avila. Yet another algorithmic bias: A discursive analysis of large language models reinforcing dominant discourses on gender and race, 2025.
- Isabel O. Gallegos, Ryan A. Rossi, Joe Barrow, Md Mehrab Tanjim, Sungchul Kim, Franck Dernoncourt, Tong Yu, Ruiyi Zhang, and Nesreen K. Ahmed. Bias and fairness in large language models: A survey. *Computational Linguistics*, 50(3), 2024.
- Maeve Madigan, Parameswaran Kamalaruban, Glenn Moynihan, Tom Kempton, David Sutton, and Stuart Burrell. Emergent bias and fairness in multi-agent decision systems, 2025.
- Kawin Mayilvaghanan, Siddhant Gupta, and Ayush Kumar. Counterfactual fairness evaluation of llm-based contact center agent quality assurance system, 2026.
- Triveni Morla, Rohith Reddy Bellibatlu, Manpreet Singh, and Manmeet Singh Kapoor. Agentfairbench: Do llm agents discriminate when they act?, 2026.
- Maya Okawa. Emergence of biased consensus in multi-agent llm debates, 2026.
- Muayad Sayed Ali, Aliaksandra Novik, Anji Boddupally, Artem Yavorskyi, Chris Nickerson, Daniel Rica, Emily DuGranrut, Felix Leung, Garrett Prince, Grace Barnett, Heath Robinson, Hosain Al Ahmad, Jesse Resnick, Juan Carlos Farah, Jyothi Swaroop Meruga, Leonid Kuznetsov, Luke Gorham, Marie Schmoll, Michael Paciullo, Saumya Das, Sharath Sheripally, Tommy Griscom, Mykyta Osadchy, Neha Mantri, Nick Westrum, Olivia Benowitz, Parikshith Kulkarni, Radik Chernyshov, Rakshith Vasudev, Rohith Nadimpally, Vikas Gangadevi, and Waseem AlShikh. The harness effect: How orchestration design sets the token economics of enterprise agentic ai, 2026.
- Kyra Wilson and Aylin Caliskan. Gender, race, and intersectional bias in resume screening via language model retrieval. In *Proceedings of the 2024 AAAI/ACM Conference on AI, Ethics, and Society (AIES)*, 2024.